

初中数学 AI 阅卷的题型误差与教师复核——基于 78 份七年级纸笔答卷的实践分析

深圳大学附属教育集团外国语中学 贾浩然

【摘要】为判断 AI 阅卷在初中数学纸笔测验中的实际适用范围，以某校七年级 78 份配对答卷为样本，比较整卷批改和混合分批批改两种方式，并对照教师手改分分析总分误差、题型误差和复核日志。原卷为总分 57 分的校内非标准化试卷，比较分析统一采用系统中的 100 分制评分口径。结果显示：整卷模式流程最终分的 MAE 为 4.49，整体偏高 2.67 分；混合模式流程最终分的 MAE 为 5.85，总分差异虽不显著，但不同题型的正负偏差存在抵消。两种模式在 Q10 作图题上的相对 MAE 均约为 24%，系统“需要复核”标记也未覆盖全部高误差题目。由此可见，AI 阅卷不能只依据总分相关性或模型置信度判断是否可用。选择、填空、计算、证明和作图题应分别设置复核要求，其中作图题仍应由教师逐项核对并确定得分。

【关键词】人工智能 初中数学 智能阅卷 题型误差 教师复核

一、问题提出

《义务教育数学课程标准（2022 年版）》提出，学生应在数与代数、图形与几何、统计与概率等内容学习中发展抽象能力、推理能力、模型观念和几何直观，并学会用符号、图形和推理过程表达数学理解^[1]。初中数学纸笔答卷中可供评分的信息因此包括最终答案、解题步骤、图形、涂改和非标准表达。课堂评价研究认为，评价应服务于学习改进；解释测验分数时，还需联系学生的实际学习过程和教师据此作出的教学决策^[2-4]。

随着大语言模型和多模态大模型的发展，一些系统已经能够直接读取扫描答卷图像，并尝试为选择、填空、计算、证明和作图等题型给出分数与理由。这类技术为减轻重复批改、加快反馈和整理错因数据提供了可能。不过，在纸笔数学测验中，识别答案内容只是评分的第一步。填空题还要处理符号等价和作废答案，证明题要判断推理链条是否充分，作图题则要核对点线位置及几何关系是否成立。这些题型的评分都需要把识别结果放回题意和评分规则中判断。

从教育测量角度看，仅有相关系数或总体准确率，尚不足以判断自动评分是否适合教学使用。效度论证既要检查测验内容和评分过程，也要说明分数应如何解释、用于何种决策，以及可能产生什么后果^[5-7]。自动评分还应针对模型、具体任务和实施流程分别评价，并在使用过程中持续监测^[8]。评分量规应明确各类作答信息与表现水平的对应关系；遇到量规不能清楚处理的争议样本时，仍需保留教师的专业判断^[9]。

据此，本研究选取真实课堂中的两种 AI 阅卷工作流进行探索性比较。整卷模式保留一名学生的完整答卷上下文；混合分批模式把同一道题的多名学生作答区域裁切、拼接后批量输入。本研究只考察两种工作流在本次测试中的表现，不据此判断某一模型对初中数学测验的普遍适用性。具体研究四个问题：（1）两种工作流在总分和题型层面的评分一致性如何；（2）不同题型的误差方向和幅度在两种输入方式下有何差异；（3）系统复核标记能否覆盖本次测试中的高误差题型；（4）本次结果对教师复核安排有何启示。

二、文献综述与分析框架

（一）大模型自动评分及其评价边界

已有研究尝试使用 LLM 对数学开放式作答题进行自动评分。Morris 等在 NAEP 数学开放式作答题上取得了接近人工评分的一致性，同时指出模型表现具有明显的题目专属性，跨任务泛化仍受限

制^[10]。Lee 等发现,思维链提示在同时提供题干和评分量规时才显著改善评分效果^[11]。Wu 等进一步发现,LLM 实际采用的评分依据可能与人工量规不一致,有时会依赖表层线索或“捷径”作出判断^[12]。在开放数学回答的评分与反馈生成中,不同模型的准确性和反馈质量也有差异^[13]。这些结果提示,单项研究中较高的一致性不能直接推及其他题目或实施条件,具体题目仍需结合题干、评分量规和学生作答分别检验。

（二）手写数学与多模态证据识别

纸笔答卷给自动评分增加了视觉识别方面的困难。FERMAT 基准显示,VLM 在检测、定位和纠正手写数学中的计算、概念、符号和呈现错误时仍有明显短板^[14]。DrawEduMath 使用教师标注的中小學生手绘数学图像,显示模型理解真实学生图形作答的能力仍有限^[15]。CHECK-MAT 将国家统一考试中的真实手写解答与细化量规结合,结果表明自动评分需要同时处理视觉理解和数学推理^[16]。VEHME 通过结构化推理数据训练和表达式感知视觉提示,提高了模型对开放式手写数学作答中错误的识别与定位能力^[17]。针对学生手绘函数图像的研究也发现,通用视觉大模型在复杂图形判断上的稳定性仍然有限^[18]。对作图题进行评分时,系统既要识别学生实际画出的内容,还要依据题意核对位置关系和几何条件。

（三）人机协同、评分量规与国内实践

在人机协同评分研究中,教师参与评分标准设计和提示词调整,并负责异常样本复核及结果使用。CoTAL 采用有人参与的提示词优化和主动学习,用于改进形成性评价评分^[19]。近期两项预印本分别研究了手写数学与 STEM 测验中的人机协同评分流程。其中一项把参考解答、细化评分量规和多次独立评分结合起来,在一致性检查后由教师最终核验;另一项使用结构化输出模板、参考解答和评分规则,并设置空白作答检测、不一致标记及人工升级处理^[20-21]。这些做法为复核流程设计提供了参考,但现有证据仍主要来自前沿技术探索。用于真实教学时,还需分别考察具体题目上的评分表现、评分依据能否说明以及教师需要承担的复核工作^[8,22]。

国内智能评卷研究已经涉及扫描网上评卷、机器辅助质检和大模型全题型评分。纸笔智能网上评卷系统将主观题识别接入扫描阅卷流程^[23];高考网评实践考察了人工智能评分参与“一评”的人机协同方式^[24];大模型全题型阅卷研究讨论了辅助定标、评分质量和过程可解释性^[25]。孙利君还将相关做法归纳为 AI 辅助质检、AI 参与赋分、专家辅助质检和双 AI 评分等实施模式^[26]。在数学教育领域,人工智能已被用于课堂教学评价和数学交流环境分析^[27];生成式 AI 与动态可视化软件的整合研究也指出,数学任务需要相应的符号和图形工具支持^[28]。智慧考试研究提出以数字化方式改进命题、投送、评分和评价流程^[29]。可信赖教育人工智能研究则强调,系统应用应满足可靠、安全和可解释等要求,并保留人的最终责任^[30]。

（四）基于数学作答证据结构的分析框架

为比较两种工作流,本文把“题型适配”具体化为两个问题:某种输入方式能否呈现该题评分所需的作答内容,以及 AI 给出分数后还需要教师检查什么。这一处理参考了课程标准对符号、图形和推理表达的要求^[1]、教育评价研究对任务与评分依据关系的讨论^[4-9],以及手写数学研究对符号识别、图形理解和空间关系判断局限的发现^[14-18]。在本次试卷中,选择题主要依据选项标记;填空题还要处理等价表达和作废规则;计算题需要查看结果与步骤;证明题需要检查条件调用和推理是否完整;作图题则要核对点线位置、作图痕迹和几何关系。后文先报告各题型的误差,再结合输入图像和复核日志讨论教师需要介入的环节。这一分类只用于组织本案例的分析,不作为已经完成外部验证的理论模型。

三、研究设计

（一）研究对象与测试材料

研究纳入某校七年级两个教学班一次阶段测试的 78 份答卷。纳入条件是同一份答卷同时具有任课教师手改记录、整卷 AI 批改记录和混合分批 AI 批改记录，三类记录可按同一份答卷一一对应。测试基于北师大版七年级下册相关内容，覆盖轴对称、角平分线性质、最短路径、一次函数图像应用和几何证明。整卷与混合模式均按每份答卷 18 个题目/小问评分单元保存日志，各形成 $78 \times 18 = 1404$ 条学生—题目/小问记录。研究文本中的姓名、班级及学号均已匿名化。试卷题型及评分任务见表 1。

表 1 试卷题型结构与评分任务特征

题号	题型及满分	主要作答证据	AI 主要任务	教师需查看并确认的内容
Q1—Q5	选择题，35 分	选项标记	识别选项并匹配答案	查看多选、涂改或异常标记，确认有效选项
Q6—Q9	填空题，32 分	符号结果、等价表达	识别符号并校验等价性	核对非标准表达是否等价，确认涂改后保留的答案
Q10	作图题，11 分（原卷 9 分）	点线位置、作图痕迹、几何关系	标出识别到的点、线及疑似位置	逐项核对点线位置及几何关系是否符合评分细则
Q11	计算/函数综合题，11 分	结果、函数关系、步骤链	提取步骤和最终结果	核对分段讨论及各步骤是否符合评分细则
Q12	几何证明题，11 分	条件调用、逻辑链、结论	列出识别到的条件、推理步骤及缺失环节	核对条件调用、推理衔接和结论是否完整

（二）AI 阅卷系统与两种批改模式

研究使用自研 AI 阅卷系统依次完成答卷定位、题目切片、模型调用和结构化结果解析，并在日志中保存模型返回的分数及复核相关字段。两种模式使用同一标准答案、同一评分细则和同一组提示要求：客观题按全对全错处理；已作废内容不计入答案；教师批改痕迹等非学生作答内容不作为评分依据；解答题列出识别到的关键步骤和缺失步骤。提示词还要求模型报告多候选答案、置信度和异常作答，供后续查看日志时使用。

两种模式按以下方式组织输入图像。整卷模式将单名学生的整卷或整页图像输入 doubao-seed-2.0-pro，原答卷中的题目位置、跨区域作答和步骤顺序随页面一并呈现。混合分批模式先裁切同一道题的学生作答区域，再将多名学生的同题区域拼接；选择、填空题每批最多 15 人，解答题每批最多 4 人，拼接完成后输入参数相同的 doubao-seed-2.0-pro。混合模式不是对每名学生逐题单独调用模型，而是在一次调用中处理同题的多名学生作答，其设计目的是限制单次输入范围，并减少调用批次以控制调用时间和 token 支出。本文比较的是上述两种输入组织方式，现有结果未单独报告调用时间或 token 成本的比较数据。具体设置见表 2。

表 2 AI 阅卷的图像输入、模型参数与日志记录设置

项目	本研究设置	核查所用记录	说明
样本与日志	78 份完整配对答卷；两模式各 1404 条日志	手改表、两模式成绩表与日志	每人 18 个题目/小问评分单元
图像输入	300 dpi；本轮两模式均未启用图像增强	扫描图像、切片与拼图	整卷：单名学生整页或整卷图像；混合：同题多名学生作答区域拼接
模型	整卷：doubao-seed-2.0-pro； 混合：doubao-seed-2.0-pro	模型日志	日志保存两种模式实际使用的模型名称
生成参数	temperature=0；top_p、top_k 采用服务端默认	调用配置	未进行同图多次重复调用

项目	本研究设置	核查所用记录	说明
评分约束	统一答案、评分细则和结构化提示词	评分细则、提示词文档	提示词包含作废内容处理、步骤提取和提示注入防护要求
复核入口	模型输出“需要复核”字段，系统据此筛选记录供教师查看	复核日志	该字段由模型报告置信度触发；置信度不作为正确概率

（三）分数定义、统计方法与案例选择

研究区分三类分数。“教师手改分”是任课教师依据统一评分细则在纸笔批改后登记的分数；“AI 原始分”是模型首次输出的分数；“流程最终分”是完成本轮系统复核流程后导出的成绩，可能沿用 AI 原始分，也可能在教师查看后调整。原卷为校内非标准化阶段测试，卷面各题标注分值合计 57 分；为便于系统统一评分，本研究的比较分析采用 100 分制评分细则，Q10 在该口径下满分为 11 分，而图 4 保留的原卷题面仍显示 9 分。本文表 1、表 3—表 5、表 7 以及各项误差指标均采用 100 分制口径。由于未设置第二评分者，教师手改分只作为本次课堂评分的专业参照，不被视为学生表现的绝对真值。本文据此考察两种 AI 批改结果与该教师手改分的差异及一致程度。

总分层面报告 Bias、MAE、RMSE、Pearson (r)、双向混合效应——绝对一致性——单测量 ICC 及其 95% 置信区间，并采用 Wilcoxon 符号秩检验和 rank-biserial correlation (r_{rb}) 评价 AI 评分与教师评分的配对差异及其效应大小。Bias 用于反映 AI 评分整体偏高或偏低的方向，MAE 反映 AI 总分与教师总分的平均绝对差异，RMSE 则对少量较大误差赋予更高权重；Pearson (r) 主要反映两种评分的线性相关和学生排序一致性，ICC 进一步评价具体分值上的绝对一致程度。

每条日志保存模型报告的置信度和“需要复核”字段；当该字段为“是”时，系统将该记录列为待教师查看。该字段由模型报告的置信度触发，本文分别统计“被标记需要复核”和“标记后流程最终分发生调整”两类记录。模型报告的置信度只作为筛选记录的信号，不解释为经过校准的正确概率。由于同一学生贡献多个题目/小问记录，同一题目也包含多名学生记录，1404 条日志并非相互独立，因此记录层结果只用于描述标记数量、题号分布和改分情况，不替代以 78 名学生为单位的总分一致性分析。

为辅助解释 Q10 的评分分歧，研究从分歧较为典型的记录中目的性选取两个脱敏案例，比较原作答中可见的点、线、文字标注、重叠痕迹和浅色痕迹。案例图未呈现逐项模型输出，因此本文不据此反推模型的内部判断过程，也不把两个案例用于频率推断。该部分仅用于说明教师在复核作图题时实际需要查看哪些内容。

四、研究结果

（一）总分层面：整卷误差较小但整体偏高

表 3 AI 原始分与流程最终分相对于教师手改分的总分差异及一致性

模式口径	教师/AI 均分	Bias	MAE	RMSE	r	ICC [95% CI]	p	r_{rb}
整卷—原始	61.44 / 65.22	+3.78	5.14	6.83	0.975	0.963 [0.940, 0.976]	<0.001	+0.72
整卷—最终	61.44 / 64.10	+2.67	4.49	5.90	0.977	0.972 [0.955, 0.982]	<0.001	+0.58
混合—原始	61.44 / 59.40	-2.03	5.99	8.27	0.943	0.940 [0.897, 0.966]	0.092	-0.23
混合—最终	61.44 / 59.96	-1.48	5.85	7.95	0.946	0.944 [0.904, 0.969]	0.241	-0.16

表 3 显示，整卷模式流程最终分的 MAE 为 4.49、RMSE 为 5.90、ICC 为 0.972，但平均高于教师手改分 2.67 分，配对差异显著。混合模式流程最终分的 MAE 为 5.85、RMSE 为 7.95、ICC 为 0.944，平均低于教师手改分 1.48 分，配对差异不显著。在本样本中，整卷模式的绝对误差较小，但存在整体偏高；混合模式未检出显著的总分差异，也不能据此解释为没有偏差。表 3 未对两种模式

各指标之差进行直接检验，因此不据这些数值判定一种模式总体优于另一种模式。两种模式最终分与教师手改分的一致性分布见图 1。




图 1 流程最终分与教师手改分的 Bland-Altman 一致性分析

(二) 排除 Q10 后：整卷偏差收窄，混合偏低更加明显

表 4 排除 Q10 作图题前后流程最终分与教师手改分的差异及一致性

模式	范围	Bias	MAE	RMSE	ICC [95% CI]	p	r_{rb}
整卷最终	总分	+2.67	4.49	5.90	0.972 [0.955, 0.982]	<0.001	+0.58
整卷最终	排除 Q10	+0.32	2.67	4.37	0.979 [0.965, 0.989]	0.742	+0.05
混合最终	总分	-1.48	5.85	7.95	0.944 [0.904, 0.969]	0.241	-0.16
混合最终	排除 Q10	-3.16	5.71	8.34	0.920 [0.859, 0.958]	0.002	-0.45

表 4 显示，排除 Q10 后，整卷模式的 Bias 由+2.67 收窄至+0.32，MAE 由 4.49 降至 2.67，配对差异不再显著；整卷总分偏高与 Q10 的正向偏差密切相关。表 5 显示，混合模式在 Q10 上的正向偏差与填空题、选择题和 Q11 的负向偏差部分抵消。混合模式的 Bias 由-1.48 变为-3.16，且配对差异转为显著。因而，Q10 是否计入会明显改变两种模式的总分 Bias 及配对检验结果；总分层面“未检出显著差异”不能被解释为各题型均无系统性偏高或偏低。Bias 变化见图 2。




图2 排除 Q10 前后流程最终分的 Bias 变化

(三) 题型层面：两种模式的误差分布不同

表5 不同题型下两种模式流程最终分的 MAE、相对 MAE 与 Bias

题型	满分	整卷 MAE (相对)	整卷 Bias	混合 MAE (相对)	混合 Bias	本样本中的相对表现
选择题 Q1—Q5	35	0.45 (1.3%)	-0.45	0.45 (1.3%)	-0.45	两模式 MAE 相同
填空题 Q6—Q9	32	1.29 (4.0%)	+0.88	3.96 (12.4%)	-3.94	本样本中整卷 MAE 较低
Q10 作图题 (原卷 9 分)	11	2.68 (24.4%)	+2.35	2.65 (24.1%)	+1.68	两模式相对 MAE 均约为 24%
Q11 计算/函数综合	11	1.00 (9.1%)	-0.92	0.60 (5.4%)	-0.54	本样本中混合 MAE 较低
Q12 几何证明	11	0.81 (7.3%)	+0.81	1.97 (17.9%)	+1.77	本样本中整卷 MAE 较低

表5和图3显示，选择题Q1—Q5中两种模式的MAE均为0.45（1.3%）。填空题Q6—Q9中，整卷模式的MAE为1.29（4.0%），混合模式为3.96（12.4%）。Q10作图题在整卷和混合模式下的MAE分别为2.68（24.4%）和2.65（24.1%），是本卷相对误差最高的题目。Q11中混合模式的MAE较低，Q12中整卷模式的MAE较低。由于每类题型只包含本卷中的有限题目，这些数值只描述本样本中的误差分布，不据此推断某一输入方式对某类题型具有稳定优势。




图 3 不同题型下两种 AI 批改模式的标准化 MAE

（四）系统“需要复核”字段：标记数量、题号分布与后续改分

表 6 两种模式中“需要复核”字段及相应改分记录

模式	日志数	“需要复核”= 是的日志数	上述日志占比	上述日志中发生分数调整的数量	上述日志所在题号	补充说明
整卷	1404	18	1.28%	1 条，下调	Q10、Q11、Q12	18 条标记中 1 条分数下调
混合	1404	11	0.78%	4 条，均上调	Q3—Q9	11 条标记中 4 条分数上调；Q10、Q12 无标记

表 6 显示，整卷模式在 1404 条日志中标记 18 条“需要复核”，标记率为 1.28%；其中 1 条记录的流程最终分下调，其余被标记记录未发生分数调整。混合模式标记 11 条，标记率为 0.78%；其中 4 条记录的流程最终分均上调，其余被标记记录未发生分数调整。整卷模式的标记主要位于 Q10、Q11 和 Q12，混合模式的标记主要位于 Q3—Q9，Q10 和 Q12 未被混合模式标记。表 5 中混合模式在 Q10 和 Q12 的相对 MAE 分别为 24.1% 和 17.9%，可见模型置信度触发的标记分布与题型相对误差的分布并不一致。本文没有“每条记录是否存在评分误差”与“是否被标记”的完整交叉数据，因此不能据表 6 计算该字段的敏感度、漏标率或误标率。

（五）Q10 脱敏案例：可观察作图痕迹与评分分歧




图 4 Q10 作图题的两个脱敏作答案例（原卷题面 9 分；统计按 100 分制计 11 分）

图 4 保留了原卷题面“本小题 9 分”的标注；本文统计采用 AI 阅卷流程中的 100 分制评分细则，Q10 按 11 分计。两份脱敏作答中，可以直接观察到多条相交线段、点名和辅助作图痕迹，部分线条或标注较浅，不同线条在网格区域内相互重叠。图下“整卷偏宽与混合偏严”“浅色作图痕迹识别风

险”是复核时对现象的简写，并非由这两个案例单独验证的因果结论。图中未列出两个案例的教师手改分、AI 原始分、流程最终分及逐项模型输出，因此不能仅凭作答图像确定模型遗漏了哪一条线、采用了何种判断路径，也不能把评分分歧确定归因于整卷页面、裁切缩放或多名学生拼接。结合表 5 中整卷和混合模式在 Q10 上分别为 24.4%和 24.1%的相对 MAE，这两个案例只能说明：识别到点线痕迹与正确确认点线归属、交点位置及几何关系并不是同一个评分步骤；案例本身不能证明某一种输入方式必然造成偏宽或偏严。

五、讨论

（一）总分结果需要结合题型偏差解读

表 4 和表 5 显示，整卷模式各题型的 Bias 相加为 $-0.45+0.88+2.35-0.92+0.81=+2.67$ ，其中 Q10 的 +2.35 约占总 Bias 的 88%，整卷总分偏高主要由这道作图题造成。混合模式中，选择题、填空题和 Q11 的负向 Bias 合计为 -4.93，Q10 和 Q12 的正向 Bias 合计为 +3.45，抵消后总 Bias 为 -1.48。因而，混合模式总分差异不显著，并不表示各题型都与教师评分接近。本次结果说明，总分指标需要与题型 Bias 和具体作答记录一并查看，尤其要核查是否有少数题目集中拉高或拉低总分。

（二）两种输入方式在本次试卷中的表现差异

表 5 中，Q12 的整卷 MAE 为 0.81，低于混合模式的 1.97；Q11 的结果相反，混合模式的 MAE 为 0.60，低于整卷模式的 1.00。一个可能的解释是，Q12 的证明需要连续查看同一名学生调用条件和推出结论的过程，整卷输入保留了完整页面；Q11 的关键步骤较短，裁切后集中呈现可能更便于核对。填空题 Q6—Q9 中，整卷 MAE 为 1.29，混合模式为 3.96，也说明缩小作答区域并不必然降低误差。由于本研究没有单独操控裁切范围、每批人数和上下文长度，这些事后解释尚不能证明某种输入方式对某类题型具有固定优势，只能作为下一轮对照研究需要检验的假设。

（三）Q10 作图题的误差来源与复核要求

表 5 中，Q10 在整卷和混合模式下的标准化 MAE 分别为 24.4%和 24.1%，明显高于本试卷其他题型；排除 Q10 后，整卷模式的 Bias 又由 +2.67 降至 +0.32。图 4 中可以看到点线重叠、浅色线条和文字标注等复核难点；图下“偏宽/偏严”等标签只作现象提示，不能替代案例级分数证据。两种模式使用同一次 300 dpi 扫描，且均未启用图像增强，这使扫描来源和名义分辨率保持一致，但不能据此排除图像因素；手写深浅、线条重叠、裁切和缩放仍可能影响作答内容是否清楚。对 Q10 这类题，教师仍需按评分细则逐项核对点线位置和几何关系。AI 可以协助呈现原图、裁切图和疑似痕迹，不宜单独决定最终得分。

（四）系统复核标记的用途与限度

表 6 显示，整卷模式在 1404 条日志中标记 18 条需复核记录，标记率为 1.28%，复核后仅有 1 条下调；混合模式标记 11 条，标记率为 0.78%，其中 4 条复核后上调。更值得注意的是，混合模式的标记主要分布在 Q3—Q9，却没有覆盖表 5 中误差较高的 Q10 和 Q12。本研究没有对模型报告的置信度进行概率校准，也没有对同一图像进行重复调用，因此该字段不能解释为答对概率，也不能用于判断输出是否稳定。实际使用时，它只能作为追加复核的提示。就本次结果而言，Q10 应直接进入教师复核，Q6—Q9 需重点核对等价表达和作废答案，Q11、Q12 则需查看关键步骤或证明过程是否完整；系统标记只是在这些检查之外增加一条提醒。各题型的暂定处理方式见表 7。

表 7 本次题型结果与暂定处理方式

本次证据	暂定处理方式	结论边界
Q1—Q5：两模式 MAE 均为 0.45（1.3%）	批量识别；多选、涂改等异常作答由教师核对	仅适用于本次选择题
Q6—Q9：整卷 MAE 为 1.29（4.0%），混合为	核对等价表达、作废答案和替换答案	尚不能确定固定输入方式

本次证据	暂定处理方式	结论边界
3.96 (12.4%)		
Q10: 整卷和混合 MAE 分别为 2.68 (24.4%) 和 2.65 (24.1%)	教师逐项复核并确定最终得分; AI 仅整理图像和提示疑似痕迹	本次证据最明确的处理建议
Q11: 混合 MAE 为 0.60 (5.4%), 整卷为 1.00 (9.1%)	后续试卷继续检验局部呈现方式	不据此宣称稳定优势
Q12: 整卷 MAE 为 0.81 (7.3%), 混合为 1.97 (17.9%)	后续试卷继续检验单份完整答卷的呈现方式	不据此宣称稳定优势
整卷、混合分别标记 18 条和 11 条; 复核后调整 1 条和 4 条	系统标记只作为追加复核提示	本研究未验证其检出能力

(五) 本次结果支持的使用判断

表 3 中, 整卷流程最终分的 MAE 为 4.49、ICC 为 0.972, 但 Bias 为 +2.67, 且与教师手改分的差异显著; 混合流程最终分的 MAE 为 5.85、ICC 为 0.944, 总 Bias 为 -1.48, 总分差异不显著。表 4 和表 5 进一步表明, 后一结果包含不同题型偏差的抵消, Q10 又是两种模式共同的高误差题目。表 6 还显示, 系统复核标记没有覆盖混合模式下的 Q10 和 Q12。综合这些结果, 本研究可以支持的判断是: 总分一致性不足以决定某类题能否交由 AI 终评, Q10 应保留教师复核, 系统复核标记只能作为补充提醒。本研究尚不能证明这套题型安排适用于其他年级、试卷或模型。

(六) 研究局限

本研究只分析了同一学校两个教学班的一次测试, 共 78 份完整配对答卷, 表 5 中的每类题型又只包含有限题目; 图 4 的两个 Q10 案例是从分歧记录中目的性选取的, 不能代表该题所有错误。教师手改没有设置第二评分者, 研究者同时参与系统设计、课堂评分和结果解释, 因此教师分也不能视为不受影响的绝对标准。模型未对同一图像重复调用, top_p、top_k 采用服务端默认参数, 表 6 中的标记率也不足以评价复核提示的检出能力。后续研究需要在不同学校和试卷中预先设定待检验的题型处理方式, 加入独立教师双评分和分歧仲裁, 并分别改变裁切范围、拼图人数和重复调用次数, 检验本次观察到的差异能否再次出现。

六、结论与建议

本研究比较了 78 份初中数学纸笔答卷在整卷和混合分批两种 AI 阅卷方式下的结果。整卷流程最终分的 MAE 为 4.49、Bias 为 +2.67; 排除 Q10 后, Bias 降至 +0.32。混合流程最终分的总 Bias 为 -1.48, 但排除 Q10 后变为 -3.16, 说明其总分结果包含正负题型偏差的抵消。两种模式在 Q10 上的标准化 MAE 均约为 24%。这些结果提示, 在本次试卷中, 判断 AI 阅卷是否可用, 不能只看总分相关或总分差异, 还需要查看误差集中在哪些题目以及这些题目的评分依据是什么。

本次结果可用于调整下一轮试用方案, 但不能直接写成普遍适用的题型规则。Q1—Q5 可继续采用批量识别和规则比对, 对多选、涂改等异常作答另行复核; Q6—Q9 需要保留等价表达和作废答案检查, 本研究尚不足以确定固定采用整卷还是局部输入。Q11 在本次混合模式下误差较低, Q12 在整卷模式下误差较低, 这两种呈现方式可以在后续试卷中继续对照。Q10 应由教师逐项核对并决定最终得分, AI 只协助整理图像和提示疑似痕迹。系统“需要复核”、模型报告的低置信度、多候选答案以及异常零分或满分, 可作为追加复核的原因; 跨模式分歧只有在同时运行两种方式时才可使用, 不能作为日常流程的必要条件。

本研究的直接证据限于本次测试: 总分结果掩盖了明显的题型差异, Q10 对整卷总分偏差影响较大, 系统复核标记又没有覆盖混合模式下误差较高的 Q10 和 Q12。由此提出的处理建议是, 实际使用时保留题目层面的误差检查, 并由教师复核作图关系、等价表达、长步骤推理和争议分数。这些处理方式仍需在更多学校、试卷和独立评分条件下验证。

参考文献

- [1]中华人民共和国教育部. 义务教育数学课程标准(2022年版)[S]. 北京: 北京师范大学出版社, 2022.
- [2]Black P, Wiliam D. Assessment and classroom learning[J]. Assessment in Education: Principles, Policy & Practice, 1998, 5(1): 7-74. DOI:10.1080/0969595980050102.
- [3]National Research Council. Knowing What Students Know: The Science and Design of Educational Assessment[M]. Washington, DC: National Academy Press, 2001. DOI:10.17226/10019.
- [4]Mislevy R J, Steinberg L S, Almond R G. On the structure of educational assessments[J]. Measurement: Interdisciplinary Research and Perspectives, 2003, 1(1): 3-62. DOI:10.1207/S15366359MEA0101_02.
- [5]Messick S, Linn R L. Educational measurement[J]. Validity, 1989: 13-103.
- [6]Kane M T. Validating the interpretations and uses of test scores[J]. Journal of Educational Measurement, 2013, 50(1): 1-73.
- [7]American Educational Research Association, American Psychological Association, National Council on Measurement in Education. Standards for Educational and Psychological Testing[M]. Washington, DC: AERA, 2014.
- [8]Williamson D M, Xi X, Breyer F J. A framework for evaluation and use of automated scoring[J]. Educational measurement: issues and practice, 2012, 31(1): 2-13.
- [9]Brookhart S M. How to Create and Use Rubrics for Formative Assessment and Grading[M]. Alexandria, VA: ASCD, 2013.
- [10]Morris W, Holmes L, Choi J S, et al. Automated scoring of constructed response items in math assessment using large language models[J]. International journal of artificial intelligence in education, 2025, 35(2): 559-586.
- [11]Lee G G, Latif E, Wu X, et al. Applying large language models and chain-of-thought for automatic scoring[J]. Computers and Education: Artificial Intelligence, 2024, 6: 100213.
- [12]Wu X, Saraf P P, Lee G G, Latif E, Liu N, Zhai X. Unveiling scoring processes: Dissecting the differences between LLMs and human graders in automatic scoring[J]. Technology, Knowledge and Learning, 2025. DOI:10.1007/s10758-025-09836-8.
- [13]Baral S, Worden E, Lim W C, et al. Automated feedback in math education: A comparative analysis of LLMs for open-ended responses[EB/OL]. arXiv:2411.08910, 2024.
- [14]Nath O, Bathina H, Khan M S U R, Khapra M M. Can vision-language models evaluate handwritten math?[C]//Proceedings of the 63rd Annual Meeting of the Association for Computational Linguistics. Vienna: ACL, 2025: 14784-14814. DOI:10.18653/v1/2025.acl-long.720.
- [15]Baral S, Lucy L, Knight R, et al. DrawEduMath: Evaluating vision language models with expert-annotated students' hand-drawn math images[C]//Proceedings of NAACL-HLT 2025. Albuquerque: ACL, 2025: 6902-6920. DOI:10.18653/v1/2025.naacl-long.352.
- [16]Khurlev R. CHECK-MAT: Probing the mathematical reasoning and rubric-alignment of vision-language models on handwritten solutions[C]//Proceedings of MathNLP 2025. Suzhou: ACL, 2025: 77-94. DOI:10.18653/v1/2025.mathnlp-main.6.
- [17]Nguyen T P, Nguyen D M, Jeon H, et al. VEHME: A vision-language model for evaluating handwritten mathematics expressions[C]//Proceedings of EMNLP 2025. Suzhou: ACL, 2025: 31793-31813.
- [18]Parsaeifard B, Hlosta M, Bergamin P. Automated grading of students' handwritten graphs: A comparison of meta-learning and vision-large language models[EB/OL]. arXiv:2507.03056, 2025.
- [19]Cohn C, Mohammed N, Biswas G. CoTAL: Human-in-the-Loop Prompt Engineering for Generalizable Formative Assessment Scoring[EB/OL]. arXiv:2504.02323, 2025.
- [20]Vanhoyweghen A, Holst V, Mobini M, et al. Human-in-the-Loop LLM Grading for Handwritten Mathematics Assessments[EB/OL]. arXiv:2603.13083, 2026.
- [21]Perš J, Muhović J, Košir A, et al. Grading Handwritten Engineering Exams with Multimodal Large Language Models[EB/OL]. arXiv:2601.00730, 2026.
- [22]Le Ying T, Hu S, Yeo D J, et al. A comprehensive review on automated grading systems in STEM using AI techniques[J]. Mathematics, 2025, 13(17): 2828.
- [23]汪张龙, 徐俊, 李晓臻, 等. 纸笔考试智能网上评卷系统的设计和应用——智能教育应用之“考试评价”篇[J]. 现代教育技术, 2018, 28(3): 5-11.
- [24]何屹松, 孙媛媛, 江光贤, 等. 人工智能评分参与高考网评一评的应用实践[J]. 中国考试, 2021(9): 40-46.
- [25]王冠, 魏兰. 人工智能大模型技术在教育考试全题型阅卷中的应用[J]. 教育测量与评价, 2024(3): 3-18.
- [26]孙利君. 人工智能辅助评卷的模式研究[J]. 浙江考试, 2025, No.443(2): 3-6.
- [27]苏洪雨, 叶珊, 许世红, 等. 基于人工智能赋能教学评价的数学交流环境研究[J]. 数学教育学报, 2025, 34(3): 1-8.
- [28]邵铭宇, 魏亮, 李均强, 等. 生成式人工智能与动态可视化软件整合: 原理、应用与展望[J]. 数学教育学报, 2025, 34(4): 27-35.
- [29]于涵. 打造智慧考试 服务智慧教育[J]. 中国考试, 2023(5): 1-10.
- [30]沈苑, 胡梦圆, 范逸洲, 汪琼. 可信人工智能教育应用的建设路径与现实启示——以英国典型举措为例[J]. 现代远程教育研究, 2023, 35(4): 65-74.

作者姓名: 贾浩然

作者单位: 深圳大学附属教育集团外国语中学

通讯地址: 广东省深圳市南山区桃源街道留仙大道 3633 号深圳大学附属教育集团外国语中学(新校区)(邮编: 518071)

联系电话: 13201469126

QQ 或微信: 894189001 (QQ)

电子邮箱: 894189001@qq.com